Proyecto – Power BI y Análisis de Datos

Análisis de datos de canciones escuchadas en *Spotify*

Propuesta:

La propuesta para este proyecto ha sido la siguiente:

Crear dos gráficos utilizando la herramienta **Power BI** con los conocimientos obtenidos en clase. Para realizar estos gráficos, se propone utilizar los datos personales de la aplicación *Spotify*. Para de esta manera poder realizar un proyecto más personal. En caso de no tener datos para utilizar, se ofrecerán datos creados para poder utilizarlos en su lugar.

Procedimiento:

Una vez obtenidos los recursos, lo primero fue analizarlos. Por un lado, tenemos una hoja de cálculo la cual contiene un listado de canciones con sus respectivos autores, reproducciones y varios datos más. Por otro lado, tenemos una carpeta con archivos *JSON* los cuales contienen datos del historial de las canciones escuchadas en distintos años. Desde el año 2019 hasta el año 2026. Para comenzar a planificar qué gráficos se harán, lo más importante es ver y entender que datos contienen los archivos. Cómo poder unir y relacionar la hoja de cálculos con los archivos *JSON*.

Durante la creación de los gráficos, el ordenador se congeló teniendo que apagarlo y perdí el proceso de tres de los gráficos realizados.

Análisis de los datos

Relacionar los archivos:

Por un lado tenemos los datos de la hoja de cálculo:

- *spotify_track_uri*
- *spotify_track_id*
- *Canción*
- *Artista*
- *Álbum*
- *Reproducciones*
- *Minutos escuchados*
- *Skips*
- *Primera escucha*
- *Última escucha*
- *Plataformas*
- *Países*
- *Archivos origen*
- *lfm_cancion*
- *lfm_artistalfm_url*
- *lfm_track_mbid*
- *lfm_duracion_ms*
- *lfm_oyentes*
- *lfm_reproducciones_globales*
- *lfm_album lfm_album_mbid*
- *lfm_album_posicion*
- *lfm_imagen_album*
- *lfm_tag_1*
- *lfm_tag_2*
- *lfm_tag_3*
- *lfm_tag_4*
- *lfm_tag_5*
- *lfm_tags*
- *lfm_wiki_publicada*
- *lfm_wiki_resumen*
- *lfm_artista_mbid*
- *lfm_artista_oyentes*
- *lfm_artista_reproducciones_globales*
- *lfm_artista_tags*
- *lfm_artistas_similares*
- *lfm_artista_bio_resumen*

- *Género principal*
- *Subgéneros / tags*
- *Fuente género*
- *Confianza género*
- *Keyword género*
- *Duración referencia ms*
- *Estado enriquecimiento*
- *Motivo no catalogadaRegistro SQLite*
- *Estado Last.fm canción*
- *Estado Last.fm artista*
- *Estado MusicBrainz*
- *Intentos*
- *Último error SQLite*
- *Actualizado en*
- *Completado en escucha*

Por otro lado, los datos de los archivos *JSON*:

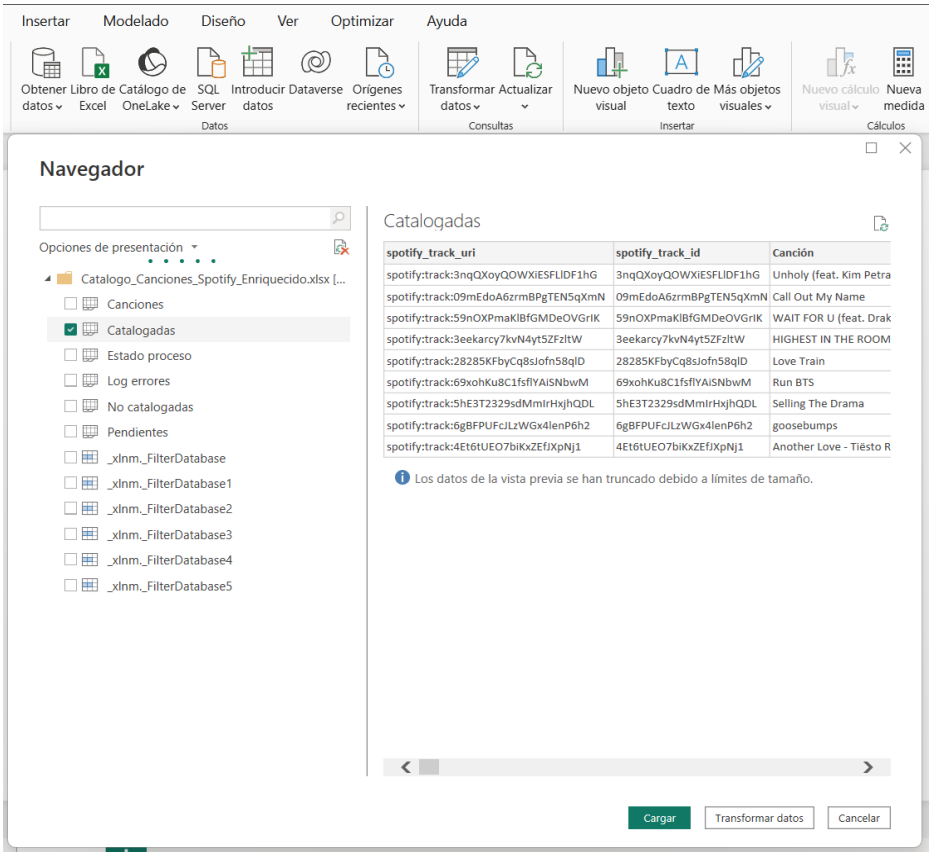
- *ts*
- *platform*
- *ms_played*
- *conn_country*
- *ip_addr*
- *master_metadata_track_name*
- *master_metadata_album_artist_name*
- *master_metadata_album_album_name*
- *spotify_track_uri*
- *episode_name*
- *episode_show_name*
- *spotify_episode_uri*
- *audiobook_title*
- *audiobook_uri*
- *audiobook_chapter_uri*
- *audiobook_chapter_title*
- *reason_start*
- *reason_end*
- *shuffle*
- *skipped*
- *offline*
- *offline_timestamp*
- *incognito_mode*

Los datos listados, serían las cabeceras de las tablas que se generarían una vez importados los archivos. Para saber si estos archivos, son compatibles para unir hay que buscar un elemento en común, el cual en este caso es el marcado en las listas: *spotify_track_uri*. Ya que este dato coincide en todos los archivos, tanto en la hoja de cálculo como en el *JSON*.

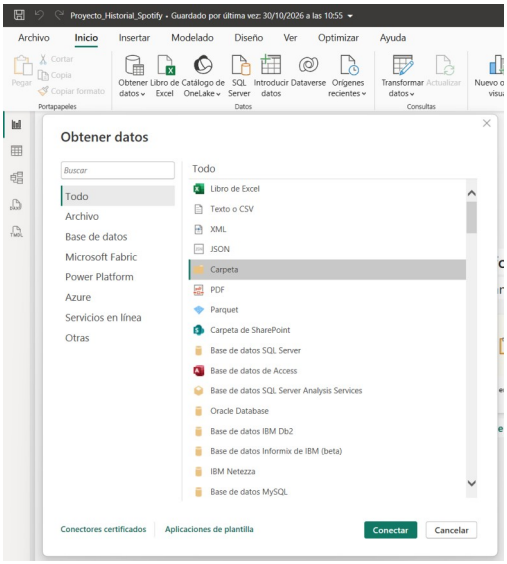
Importar archivos y relacionar:

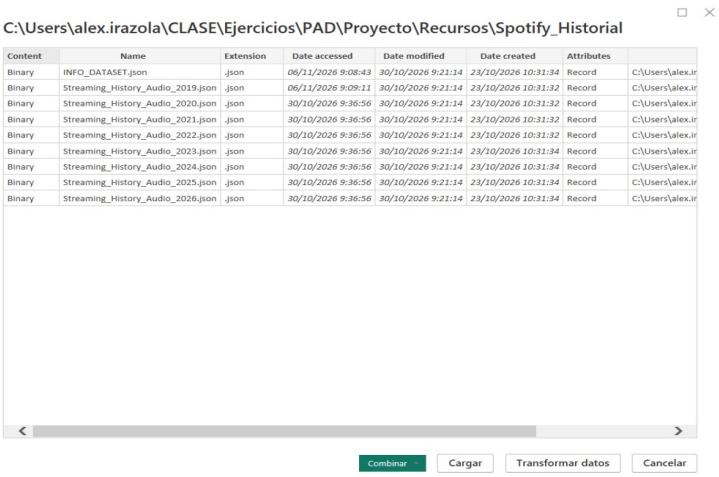
Antes de poder tratar los datos, el primer paso a tomar es el importar todos los archivos a la aplicación **Power BI** para poder transformarlos ahí. Para importar los datos, se realizaron dos procedimientos distintos.

Primero, importamos la hoja de cálculos y elegimos que hoja de este archivo queremos utilizar. En nuestro caso, elegimos la hoja de Catalogadas para tener que limpiar menos datos vacios, null o errores.



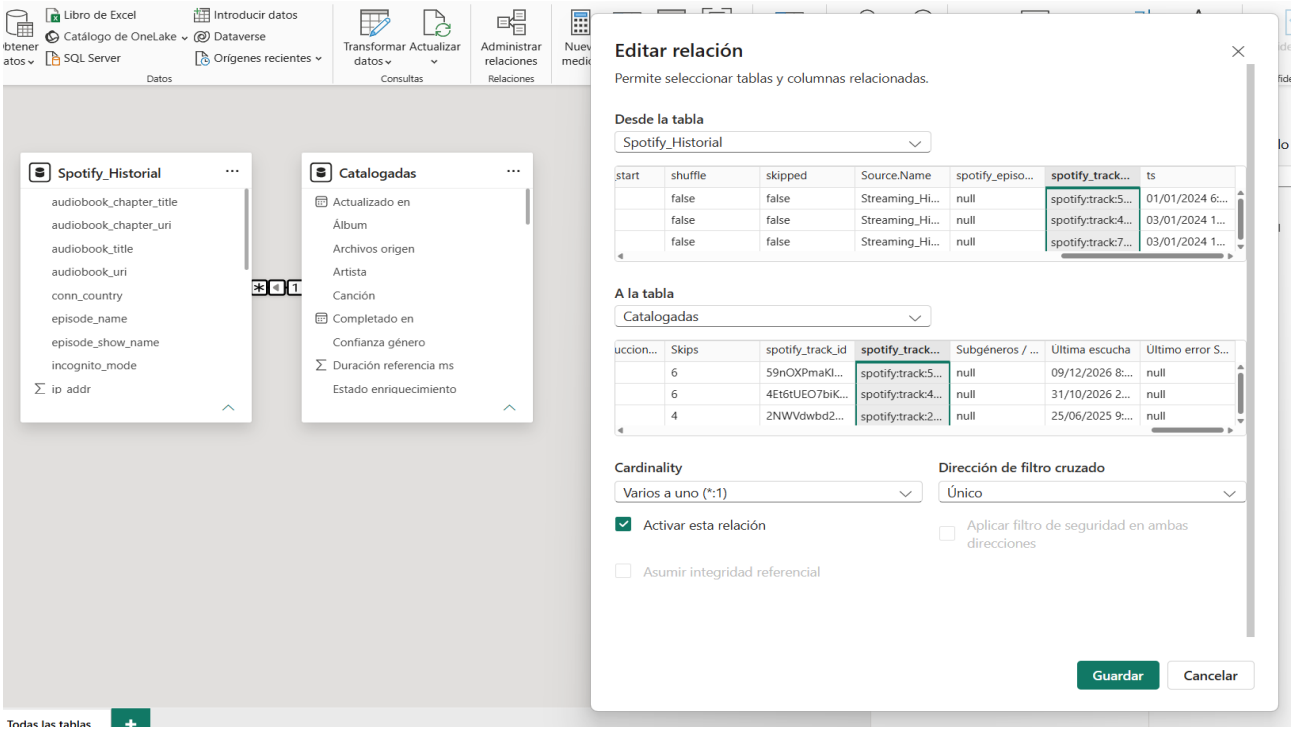
Para importar los archivos *JSON*, se hizo mediante la selección de una carpeta. De esta manera obtuvo todos los que residían en esta. De estos archivos, en caso de haber alguno no deseado, como es en este caso el *INFO_DATASET.json*, se elimina la fila de este antes de unir los demás *JSON*.





Una vez importados todos los datos, confirmamos que ambas tablas están relacionadas correctamente, o en caso de que no esté la relación echa, para crearla. En la imagen añadida a continuación se puede apreciar como la relación se ha

realizado de manera automática por la columna previamente analizada: *spotify_track_uri*. Una vez confirmado que todo está correcto, pasamos a la siguiente fase.



Limpiar datos:

Para poder limpiar los datos de manera adecuada, primeros los importamos a **Power BI**. Relacionamos las tablas que se generaron y comenzamos a limpiar los datos que no necesitamos mediante el uso de las herramientas que ofrece el transformar datos. Para que así, se nos facilite el trabajo de elegir que datos usar más adelante.

Por un lado, en la tabla de Catalogadas obtenida de la hoja de cálculos, tenemos las siguientes columnas con datos repetidos o innecesarios para el proyecto que vamos a realizar:

Archivos origen

- *lfm_url*
- *lfm_track_mbid*
- *lfm_album_mbid*
- *lfm_album_posicion*
- *lfm_imagen_album*
- *lfm_tag_1*
- *lfm_tag_2*
- *lfm_tag_3*
- *lfm_tag_4*
- *lfm_tag_5*
- *lfm_wiki_resumen*
- *lfm_artista_bio_resumen*
- *lfm_artista_mbid*
- *Fuente género*
- *Confianza género*
- *Estado enriquecimiento*
- *Motivo no catalogada*
- *Registro SQLite*
- *Estado Last.fm canción*
- *Estado Last.fm artista*
- *Estado MusicBrainz*
- *Intentos*
- *Último error SQLite*
- *Actualizado en*
- *Completado en*

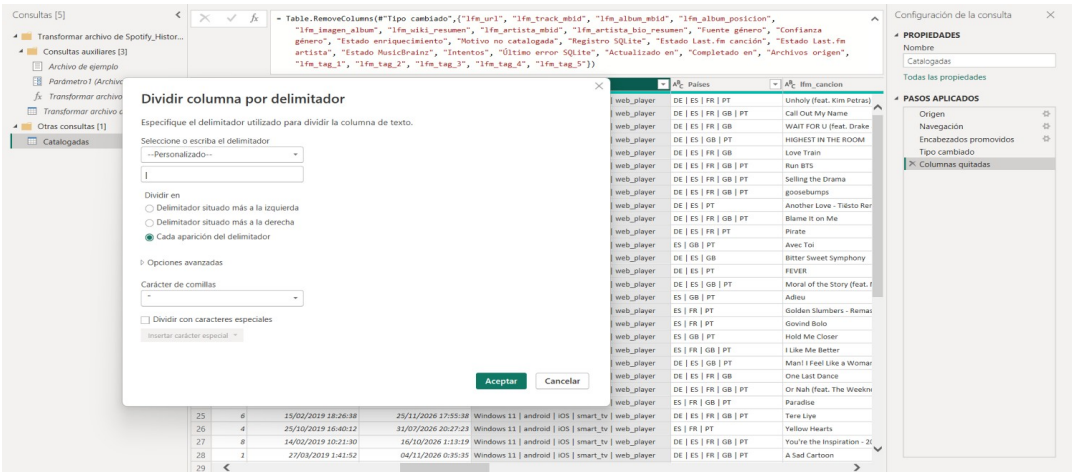
A su vez, en la tabla creada por la unión de los archivos *JSON*, se eliminaron las siguientes columnas que no tenían valores:

- *episode_name*
- *episode_show_name*
- *spotify_episode_uri*
- *audiobook_title*
- *audiobook_uri*
- *audiobook_chapter_uri*
- *audiobook_chapter_title*

Con las columnas no necesarias eliminadas, se vuelve a analizar las tablas que han quedado para eliminar filas que estén vacías o columnas que se puedan unir o dividir por delimitador para tener más datos.

Las siguientes columnas son las decididas para dividir. Ya que son un conjunto de valores separados por el valor " | ":

- *Plataformas*
- *Países*
- *lfm_tags*
- *lfm_artista_tags*
- *lfm_artistas_similares*
- *Subgéneros / tags*



Tras dividir las columnas, hay que revisar los resultados obtenidos de esta acción. Ya que puede haber columnas con pocos valores que pueden ser prescindibles. Esto se puede apreciar en las barras mostradas debajo del nombre de la cabecera de la columna. Siendo los colores de esta, representativos de datos (verde), *null* o vacío (gris), errores (rojo)…

En nuestro caso, las columnas prescindibles fueron las siguientes:

- *Plataformas.4*
- *Plataformas.5*
- *Países.4*
- *Países.5*

Selección de datos:

Una vez echa una limpieza de los datos que se nos ha proporcionado, el siguiente paso es decidir que datos pueden ser de mayor interés a analizar. Como por ejemplo:

- *Canción*
- *Artista*
- *Album*
- *lfm_duracion_ms*
- *lfm_oyentes*
- *lfm_reproducciones_globales*
- *lfm_tag_1*
- *lfm_tag_2*
- *lfm_tag_3*
- *lfm_tag_4*

- *lfm_tag_5*
- *lfm_wiki_publicada*
- *lfm_artista_oyentes*
- *lfm_artista_reproducciones_globales*
- *lfm_artista_tags (Hay que separarlos o no)*
- *Subgéneros / tags*
- *Keyword género*

O a su vez, en caso de la tabla nacida de los *JSON*:

- *ts*
- *platform*
- *ms_played*
- *conn_country*
- *master_metadata_track_name*
- *master_metadata_album_artist_name*
- *master_metadata_album_album_name*
- *shuffle*
- *skipped*
- *offline*
- *offline_timestamp*
- *incognito_mode*

Creación de gráficos

Recopilar ideas:

Para poder comenzar a generar gráficos, lo más importante es obtener ideas de qué datos queremos mostras y a qué conclusiones llegar.

Estas son las ideas propias para crear gráficos:

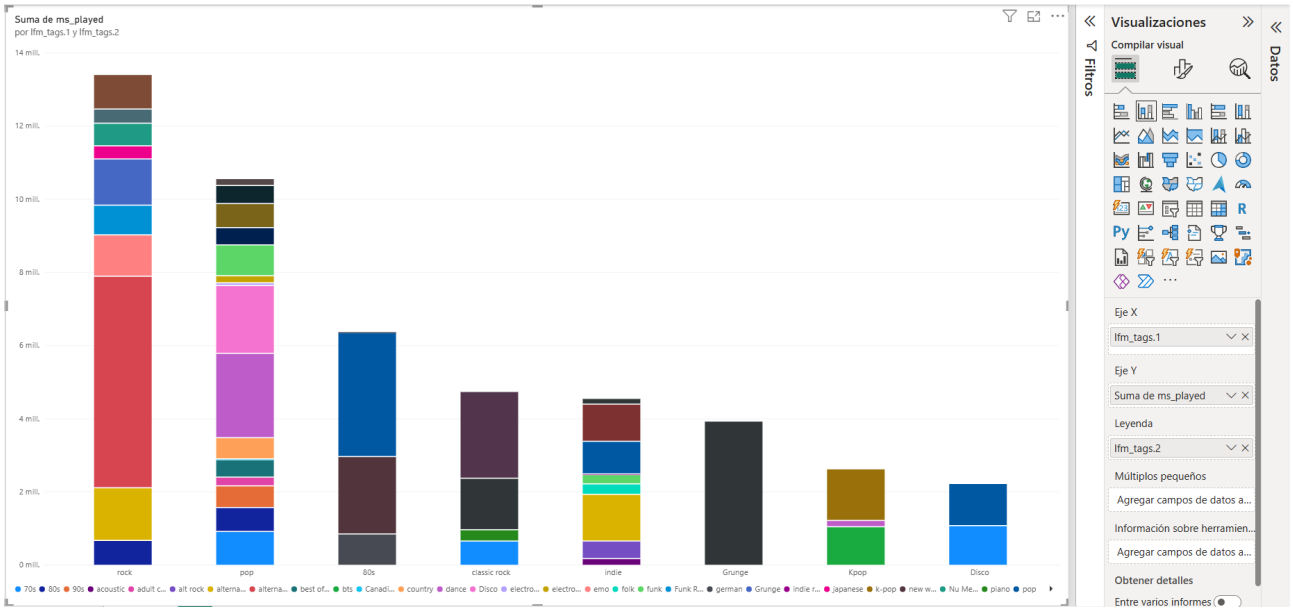
1. *Cuantos ms he escuchado de los géneros ROCK, POP, 80s, CLASSIC ROCK, INDIE, GRUNGE, KPOP y DISCO y los distintos segundos géneros más escuchados de estos.*
2. *De los artistas más escuchados, cuantas veces han sido skippeados.*
3. *Los álbumes skippeados con más ms escuchados, en qué paises se han escuchado.*
4. *Por plataformas, ver escuchando en suffle, que cantidad se skippea y que no.*

Estas son las ideas propuestas:

- *Top 10 artistas por minutos escuchados.*
- *Top 10 géneros por minutos escuchados.*
- *Evolución de los minutos escuchados por año.*
- *Minutos escuchados según la hora del día.*
- *Evolución del uso de las distintas plataformas de Spotify a lo largo de los años.*

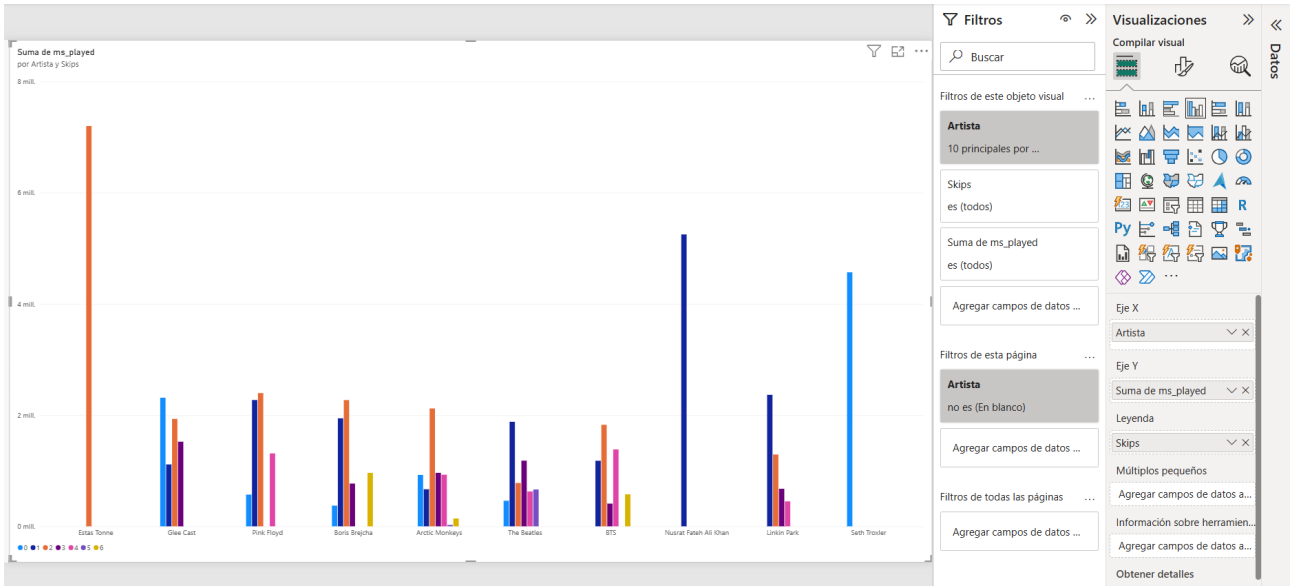
Gráficos realizados:

El primer gráfico realizado ha sido el de la idea nº1. He decidido utilizar un gráfico de columnas apiladas para así poder ver de manera más visual los subgéneros dentro de los géneros principales. Para poder realizar este gráfico, he usado los datos obtenidos de Catalogadas para colocar en el eje X y la leyenda. En el eje X he colocado el valor de *lfm_tags.1* que es el primer género de las canciones. Mientras que en la leyenda he colocado el valor de *lfm_tags.2* que es el subgénero. Finalmente, en el eje Y he colocado el valor obtenido de los json de *Suma de ms_played*.



El segundo gráfico ha sido el de la idea nº2. Utilizando un gráfico de columans apiladas quiero mostrar la cantidad de veces en las que se han skippeado los 10 artistas más escuchados. En este gráfico he utilizado los siguientes datos: en el eje X *Artistas*, en el eje Y *Suma de ms_played* y en leyenda *Skips*. Para poder mostrar los que quería, he aplicado los siguientes filtros:

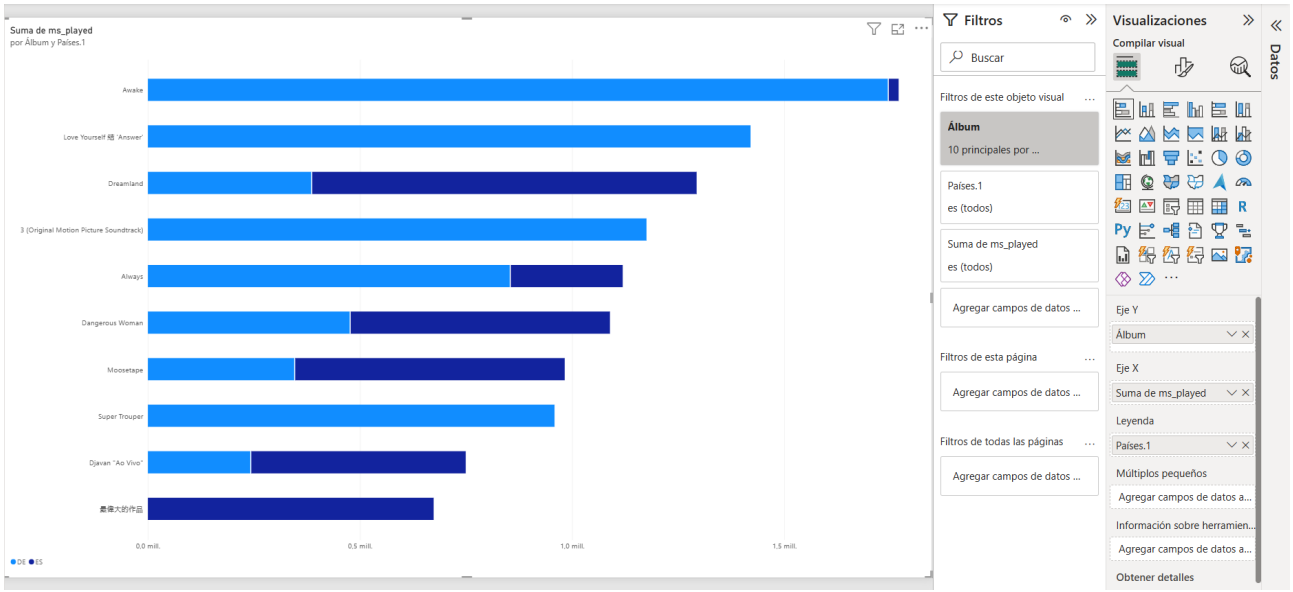
- Filtrando en artista, por los 10 primeros que más cantidad de ms_played tienen.
- Tambien he filtrado para que no aparezcan los artistas con nombre en blanco.



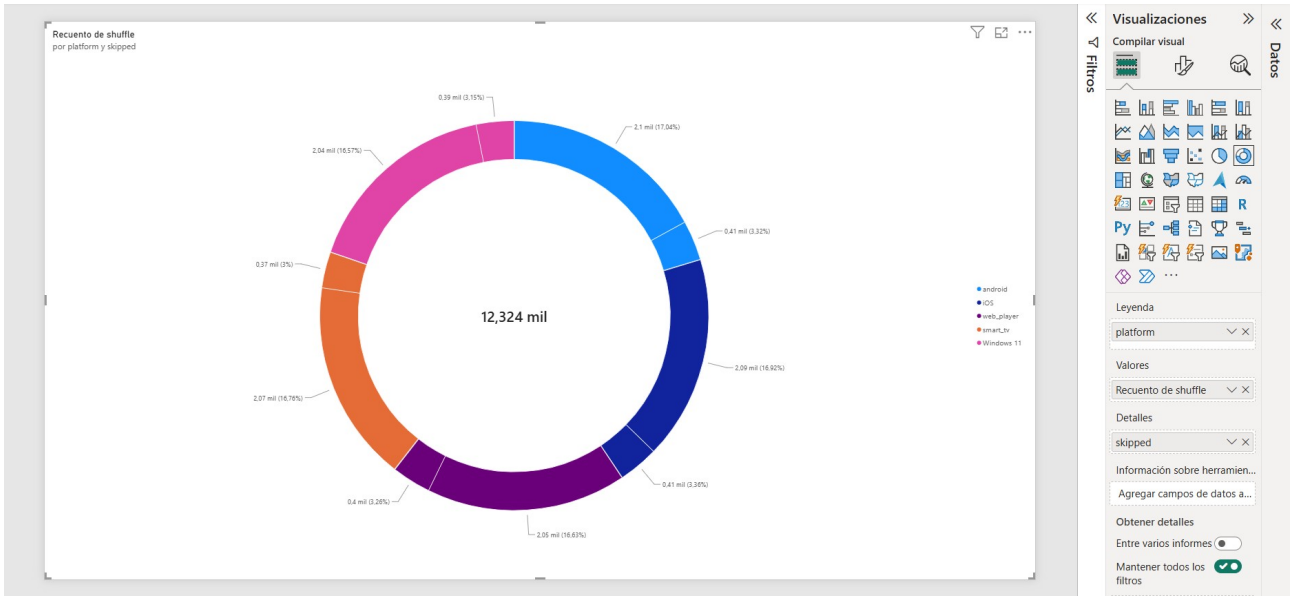
El tercero es de la idea nº3, utilizando un gráfico de barras apiladas. En qué paises he escuchado las canciones que más he skipeado y escuchado (las skippeadas más escuchadas, ya que una cosa no implica que no pueda ser la otra.). Para

crear este gráfico he utilizado los valores *Album* (en el eje Y), *Suma de ms_played* (en el eje X) y *Paises.1* (Leyenda). Para poder mostrar los que quería, he aplicado los siguientes filtros:

- Filtrando en album, por los 10 primeros que más cantidad de skip tienen.



El cuarto gráfico es un gráfico de anillos, lo baso en la 4ª idea. El propósito de este gráfico es el poder ver si dependiendo de la plataforma, a la hora de escuchar en suffle se skippea más o menos. Tras hacer el gráfico se ha podido observar que independientemente de la plataforma, al escuchar en suffle, la cantidad de skippeo es parecido. Para poder realizar este gráfico he utilizado tres valores. Por un lado platform para la leyenda, recuento de shuffle para los valores y skipped para detalles.



Para el último gráfico he decidido utilizar el ejemplo Top 10 géneros por minutos escuchados con un gráfico circular para que sea más visible. Para este gráfico solo he necesitado dos campos, para la leyenda *lfm_tags.1* y para los valores

Suma de ms_played. También he tenido que aplicar un par de filtros. Para que muestre el top 10 de *ms_played* y que no aparezcan las *lfm_tags.1* vacías.

