Proyecto – Power BI y Análisis de Datos

Análisis de datos de canciones escuchadas en *Spotify*

Propuesta:

La propuesta para este proyecto ha sido la siguiente:

Crear dos gráficos utilizando la herramienta **Power BI** con los conocimientos obtenidos en clase. Para realizar estos gráficos, se propone utilizar los datos personales de la aplicación *Spotify*. Para de esta manera poder realizar un proyecto más personal. En caso de no tener datos para utilizar, se ofrecerán datos creados para poder utilizarlos en su lugar.

Procedimiento:

Una vez obtenidos los recursos, lo primero fue analizarlos. Por un lado, tenemos una hoja de cálculo la cual contiene un listado de canciones con sus respectivos autores, reproducciones y varios datos más. Por otro lado, tenemos una carpeta con archivos *JSON* los cuales contienen datos del historial de las canciones escuchadas en distintos años. Desde el año 2019 hasta el año 2026. Para comenzar a planificar qué gráficos se harán, lo más importante es ver y entender que datos contienen los archivos. Cómo poder unir y relacionar la hoja de cálculos con los archivos *JSON*.

Análisis de los datos

Relacionar los archivos:

Por un lado tenemos los datos de la hoja de cálculo:

- *ts*
- *platform*
- *ms_played*
- *conn_country*
- *ip_addr*
- *master_metadata_track_name*
- *master_metadata_album_artist_name*
- *master_metadata_album_album_name*
- *spotify_track_uri*
- *episode_name*
- *episode_show_name*
- *spotify_episode_uri*
- *audiobook_title*
- *audiobook_uri*
- *audiobook_chapter_uri*
- *audiobook_chapter_title*
- *reason_start*
- *reason_end*
- *shuffle*
- *skipped*
- *offline*
- *offline_timestamp*
- *incognito_mode*

Por otro lado, los datos de los archivos *JSON*:

- *ts*
- *platform*
- *ms_played*
- *conn_country*
- *ip_addr*
- *master_metadata_track_name*
- *master_metadata_album_artist_name*
- *master_metadata_album_album_name*
- *spotify_track_uri*
- *episode_name*
- *episode_show_name*
- *spotify_episode_uri*
- *audiobook_title*
- *audiobook_uri*

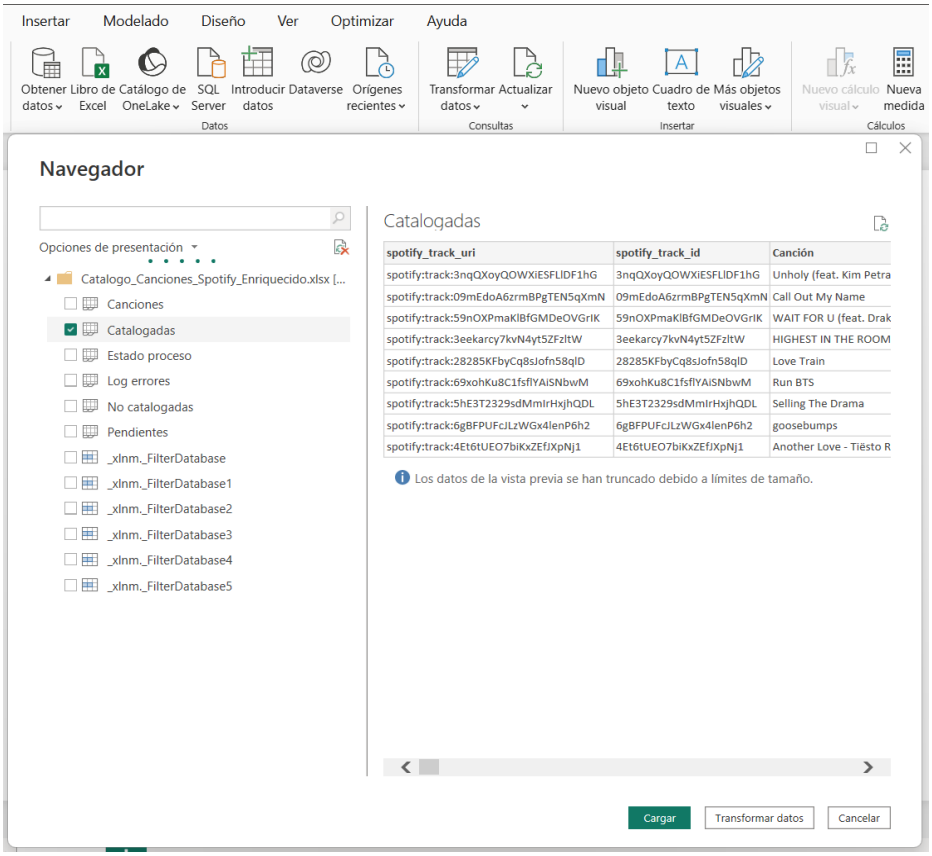
- *audiobook_chapter_uri*
- *audiobook_chapter_title*
- *reason_start*
- *reason_end*
- *shuffle*
- *skipped*
- *offline*
- *offline_timestamp*
- *incognito_mode*

Los datos listados, serían las cabeceras de las tablas que se generarían una vez importados los archivos. Para saber si estos archivos, son compatibles para unir hay que buscar un elemento en común, el cual en este caso es el marcado en las listas: *spotify_track_uri*. Ya que este dato coincide en todos los archivos, tanto en la hoja de cálculo como en el *JSON*.

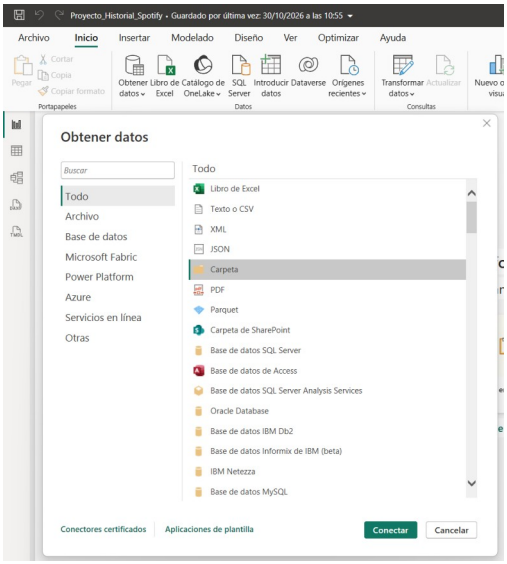
Importar archivos y relacionar:

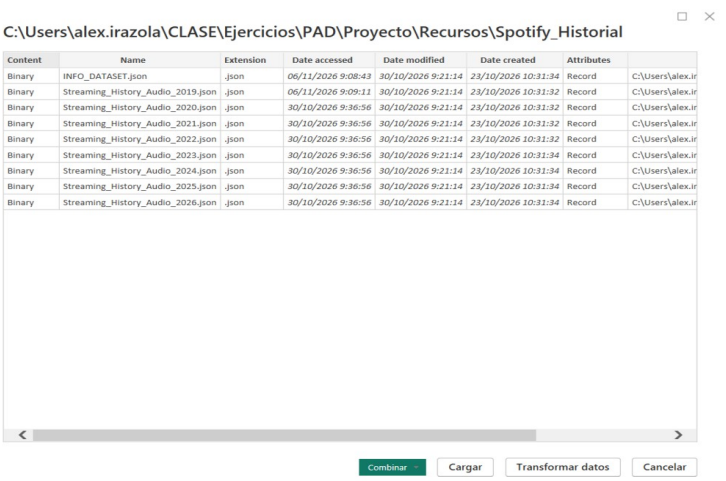
Antes de poder tratar los datos, el primer paso a tomar es el importar todos los archivos a la aplicación **Power BI** para poder transformarlos ahí. Para importar los datos, se realizaron dos procedimientos distintos.

Primero, importamos la hoja de cálculos y elegimos que hoja de este archivo queremos utilizar. En nuesto caso, elegimos la hoja de Catalogadas para tener que limpiar menos datos vacios, null o errores.

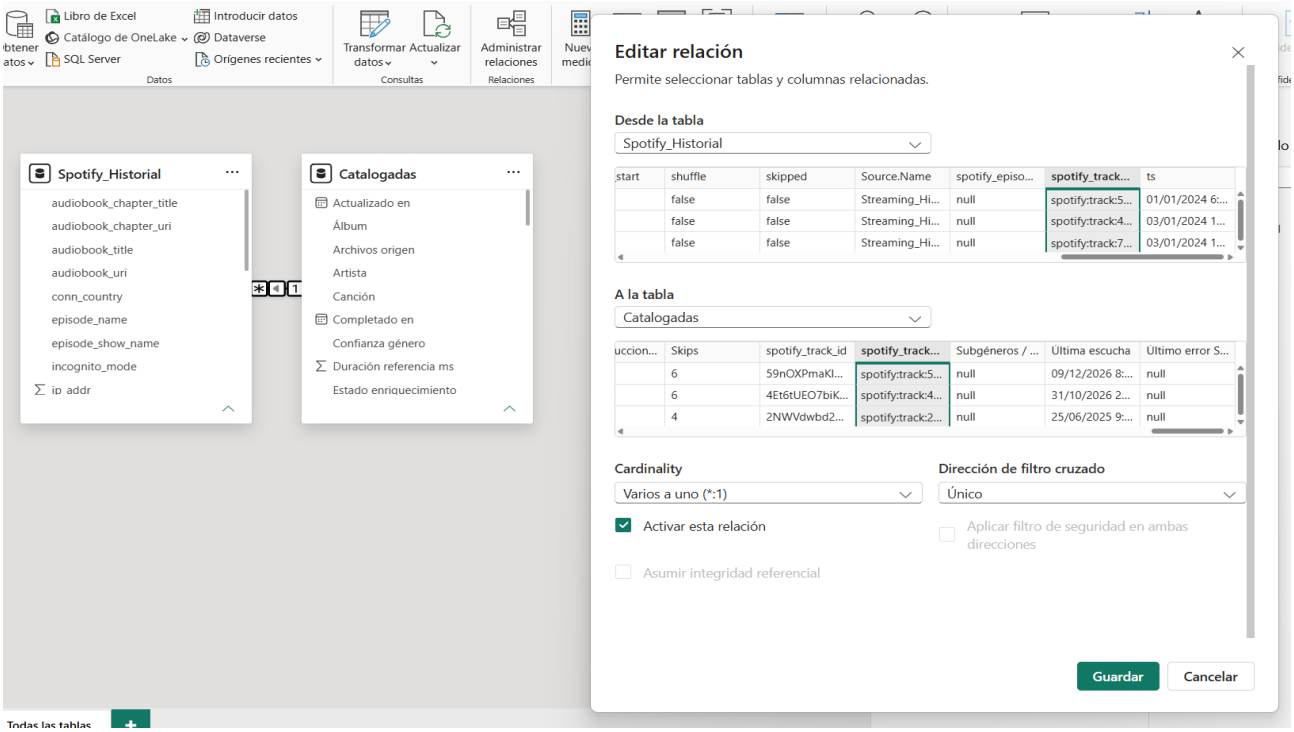


Para importar los archivos *JSON*, se hizo mediante la selección de una carpeta. De esta manera obtuvo todos los que residían en esta. De estos archivos, en caso de haber alguno no deseado, como es en este caso el *INFO_DATASET.json*, se elimina la fila de este antes de unir los demás *JSON*.





Una vez importados todos los datos, confirmamos que ambas tablas están relacionadas correctamente, o en caso de que no esté la relación echa, para crearla. En la imagen añadida a continuación se puede apreciar como la relación se ha realizado de manera automática por la columna previamente analizada: *spotify_track_uri*. Una vez confirmado que todo está correcto, pasamos a la siguiente fase.



Limpiar datos:

Para poder limpiar los datos de manera adecuada, primeros los importamos a **Power BI**. Relacionamos las tablas que se generaron y comenzamos a limpiar los datos que no necesitamos mediante el uso de las herramientas que ofrece el transformar datos. Para que así, se nos facilite el trabajo de elegir que datos usar más adelante.

Por un lado, en la tabla de Catalogadas obtenida de la hoja de cálculos, tenemos las siguientes columnas con datos repetidos o innecesarios para el proyecto que vamos a realizar:

Archivos origen

- *lfm_url*
- *lfm_track_mbid*
- *lfm_album_mbid*
- *lfm_album_posicion*
- *lfm_imagen_album*
- *lfm_tag_1*
- *lfm_tag_2*
- *lfm_tag_3*
- *lfm_tag_4*
- *lfm_tag_5*
- *lfm_wiki_resumen*
- *lfm_artista_bio_resumen*
- *lfm_artista_mbid*
- *Fuente género*
- *Confianza género*
- *Estado enriquecimiento*
- *Motivo no catalogada*
- *Registro SQLite*
- *Estado Last.fm canción*
- *Estado Last.fm artista*
- *Estado MusicBrainz*
- *Intentos*
- *Último error SQLite*
- *Actualizado en*
- *Completado en*

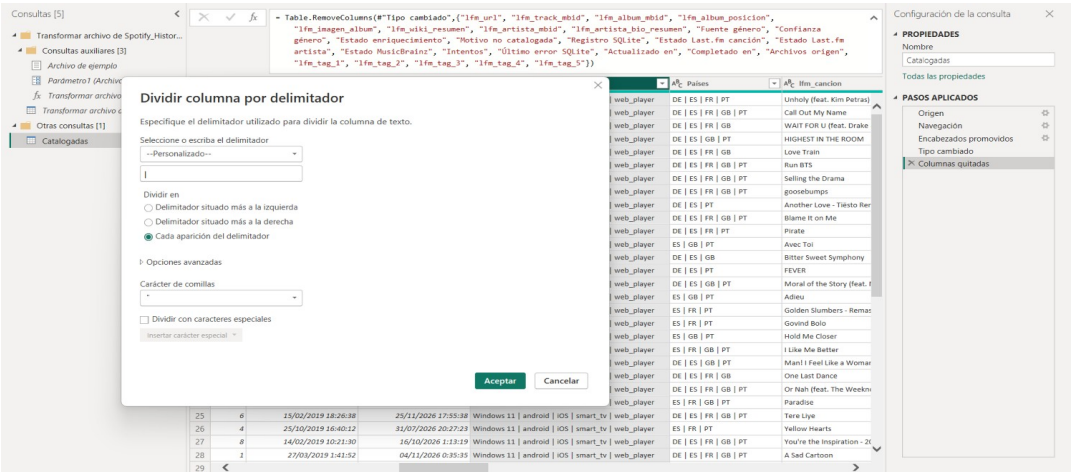
A su vez, en la tabla creada por la unión de los archivos *JSON*, se eliminaron las siguientes columnas que no tenían valores:

- *episode_name*
- *episode_show_name*
- *spotify_episode_uri*
- *audiobook_title*
- *audiobook_uri*
- *audiobook_chapter_uri*
- *audiobook_chapter_title*

Con las columnas no necesarias eliminadas, se vuelve a analizar las tablas que han quedado para eliminar filas que estén vacías o columnas que se puedan unir o dividir por delimitador para tener más datos.

Las siguientes columnas son las decididas para dividir. Ya que son un conjunto de valores separados por el valor “ | ”:

- *Plataformas*
- *Países*
- *lfm_tags*
- *lfm_artista_tags*
- *lfm_artistas_similares*
- *Subgéneros / tags*



Tras dividir las columnas, hay que revisar los resultados obtenidos de esta acción. Ya que puede haber columnas con pocos valores que pueden ser prescindibles. Esto se puede apreciar en las barras mostradas debajo del nombre de la cabecera de la columna. Siendo los colores de esta, representativos de datos (verde), *null* o vacío (gris), errores (rojo)…

En nuestro caso, las columnas prescindibles fueron las siguientes:

- *Plataformas.4*
- *Plataformas.5*
- *Países.4*
- *Países.5*

Selección de datos:

Una vez echa una limpieza de los datos que se nos ha proporcionado, el siguiente paso es decidir que datos pueden ser de mayor interés a analizar. Como por ejemplo:

- *Canción*
- *Artista*
- *Album*
- *lfm_duracion_ms*
- *lfm_oyentes*
- *lfm_reproducciones_globales*
- *lfm_tag_1*
- *lfm_tag_2*
- *lfm_tag_3*
- *lfm_tag_4*
- *lfm_tag_5*
- *lfm_wiki_publicada*
- *lfm_artista_oyentes*
- *lfm_artista_reproducciones_globales*
- *lfm_artista_tags (Hay que separarlos o no)*
- *Subgéneros / tags*
- *Keyword género*

O a su vez, en caso de la tabla nacida de los *JSON*:

- *ts*
- *platform*
- *ms_played*
- *conn_country*
- *master_metadata_track_name*
- *master_metadata_album_artist_name*
- *master_metadata_album_album_name*
- *shuffle*
- *skipped*
- *offline*
- *offline_timestamp*
- *incognito_mode*

Creación de gráficos

Recopilar ideas:

Para poder comenzar a generar gráficos, lo más importante es obtener ideas de qué datos queremos mostras y a qué conclusiones llegar.

Estas son las primeras ideas:

- *Plataformas.4*
- *Plataformas.5*
- *Países.4*
- *Países.5*